

Сокращение размерности. Глава 1.

1. **Размерности** — переменные или характеристики данных (столбцы в матрице X). $X (N \times P)$: N — число наблюдений (строк), P — число признаков (столбцов). Чем больше признаков, тем сложнее данные. Алгоритм лучше всего работает именно с непрерывными данными.
2. **Сокращение размерности**: мы берём данные с высокой размерностью ($p > 4$) и «упрощаем» их (до $p = 2$). То есть, мы представляем полное пространство данных высокой размерности в подпространстве меньшей размерности.

Например, МГК (РСА) — метод, уменьшающий размерность и максимизирующий общую дисперсию. Первая ГК определяется через направление наибольшей вариации данных, последующие компоненты ортогональны предыдущим, что отражает уникальные данные. Определение числа компонент зависит от исследователя, но количество компонент должно быть $< p$, так как из любого пространства X можно извлечь до p компонент.

УМАР — изучение геометрического пространства и геометрических паттернов, которые лежат в пространстве высокой размерности, и, основываясь на расстояниях между наблюдениями, уменьшает размерность исходных данных. Свои основания UMAP (Uniform Manifold Approximation and Projection) берёт в методе t-SNE (t-distributed Stochastic Neighbor Embedding).

Про массив данных: термометр чувств от 1 до 100 по поводу того, какие чувства респонденты испытывают к тому или иному человеку/феномену. Ценность в том, что они, скорее всего, коллинеарны. **Гипотеза**: структура ответов на эти термометры будет формироваться по партийной линии.

LLE имеет схожую с РСА интуицию: основан на идее «многообразного» обучения через изучение локальной структуры (из соседних значений) и дальнейшей её интерпретации на глобальную структуру. Метод подходит, если данные не выражаются линейно. Он сохраняет локальные связи между точками, что позволяет работать с более сложными структурами данных. Схожим образом работают t-SNE и UMAP, а также нейронные модели: SOM и autoencoders.

Чем РСА отличается от факторного анализа? Факторный анализ предполагает ряд предварительных допущений о гауссовском распределении и существовании условной независимости между переменными. Фокус на латентных переменных, каузальная модель, которая пытается выявить скрытые факторы.

Очистка данных. Два подхода для очистки данных в R: базовый синтаксис и tidy-подход. Tidy-подход — использование операторов `%>%` для написания нескольких операций в одной функции. Вместо удаления используется импутация, то есть вычисленные правдоподобные значения. Также рекомендуется задуматься и о причинах пропусков значений. В случае случайных пропусков используется множественная импутация с помощью kNN: выбираются ближайшие непустые значения и берётся их среднее.

Классический подход к сокращению размерности. Глава 2.

РСА (МГК). Линейный подход к снижению размерности, который уменьшает сложность путем максимизации дисперсии (информативности). Изначально предполагается, что дисперсия — лучший способ концептуализации структуры в пространстве данных.

Почему РСА? МГК делает пространство высокой размерности менее сложным, позволяет бороться с мультиколлинеарностью. Также, снижение размерности помогает бороться с "проклятием размерности с точки зрения которого, настоящие сходства и различия между признаками становятся все менее очевидными.

Дисперсия задает критерий оптимальности, РСА начинается с поиска направления в данных, вдоль которого наблюдается БОЛЬШОЙ разброс. После нахождения направления проводится обобщаемая прямая — ГК, которая и отражает направление максимальной дисперсии (ГК1). ГК1 объясняет не все данные, поэтому мы ищем ГК пока не будет объяснено все пространство данных, пока $C^* = p$, где p — исходная размерность. Наша задача — сосредоточиться на подмножестве компонент, чтобы $C^* < p$, чтобы упростить данные. Уникальность компонент определяется требованием, чтобы каждая компонента была ортогональна всем остальным. То есть, каждая новая компонента объясняет уникальную вариацию в данных.

Формализация PCA. Так как PCA – частный случай линейной регрессии, то уравнение строится аналогичным образом, но без оценивания параметров и свободного члена. Каждый признак вносит свой вклад в вычисление главных компонент, веса называются нагрузками (loadings). Для поиска оптимальных значений предлагается использование SVD (сингулярное разложение матрицы). Последним шагом является выбор кол-ва ГК через PVE (долю объясненной дисперсии). PVE в диапазоне от 75–80 процентов. CPVE – накопленная доля объясненной дисперсии, равная 1. Главная проблема PCA – неопределенность относительно метода выбора ГК.