

Сокращение размерности. Глава 1.

1. **Размерности** — переменные или характеристики данных (столбцы в матрице X). $X (N \times P)$: N — число наблюдений (строк), P — число признаков (столбцов). Чем больше признаков, тем сложнее данные. Алгоритм лучше всего работает именно с непрерывными данными.
2. **Сокращение размерности**: мы берём данные с высокой размерностью ($p > 4$) и «упрощаем» их (до $p = 2$). То есть, мы представляем полное пространство данных высокой размерности в подпространстве меньшей размерности.

Например, МГК (РСА) — метод, уменьшающий размерность и максимизирующий общую дисперсию. Первая ГК определяется через направление наибольшей вариации данных, последующие компоненты ортогональны предыдущим, что отражает уникальные данные. Определение числа компонент зависит от исследователя, но количество компонент должно быть $< p$, так как из любого пространства X можно извлечь до p компонент.

УМАР — изучение геометрического пространства и геометрических паттернов, которые лежат в пространстве высокой размерности, и, основываясь на расстояниях между наблюдениями, уменьшает размерность исходных данных. Свои основания UMAP (Uniform Manifold Approximation and Projection) берёт в методе t-SNE (t-distributed Stochastic Neighbor Embedding).

Про массив данных: термометр чувств от 1 до 100 по поводу того, какие чувства респонденты испытывают к тому или иному человеку/феномену. Ценность в том, что они, скорее всего, коллинеарны. **Гипотеза**: структура ответов на эти термометры будет формироваться по партийной линии.

LLE имеет схожую с РСА интуицию: основан на идее «многообразного» обучения через изучение локальной структуры (из соседних значений) и дальнейшей её интерпретации на глобальную структуру. Метод подходит, если данные не выражаются линейно. Он сохраняет локальные связи между точками, что позволяет работать с более сложными структурами данных. Схожим образом работают t-SNE и UMAP, а также нейронные модели: SOM и autoencoders.

Чем РСА отличается от факторного анализа? Факторный анализ предполагает ряд предварительных допущений о гауссовском распределении и существовании условной независимости между переменными. Фокус на латентных переменных, каузальная модель, которая пытается выявить скрытые факторы.

Очистка данных. Два подхода для очистки данных в R: базовый синтаксис и tidy-подход. Tidy-подход — использование операторов `%>%` для написания нескольких операций в одной функции. Вместо удаления используется импутация, то есть вычисленные правдоподобные значения. Также рекомендуется задуматься и о причинах пропусков значений. В случае случайных пропусков используется множественная импутация с помощью kNN: выбираются ближайшие непустые значения и берётся их среднее.

Классический подход к сокращению размерности. Глава 2.

РСА (МГК). Линейный подход к снижению размерности, который уменьшает сложность путем максимизации дисперсии (информативности). Изначально предполагается, что дисперсия — лучший способ концептуализации структуры в пространстве данных.

Почему РСА? МГК делает пространство высокой размерности менее сложным, позволяет бороться с мультиколлинеарностью. Также, снижение размерности помогает бороться с "проклятием размерности с точки зрения которого, настоящие сходства и различия между признаками становятся все менее очевидными.

Дисперсия задает критерий оптимальности, РСА начинается с поиска направления в данных, вдоль которого наблюдается БОЛЬШОЙ разброс. После нахождения направления проводится обобщаемая прямая — ГК, которая и отражает направление максимальной дисперсии (ГК1). ГК1 объясняет не все данные, поэтому мы ищем ГК пока не будет объяснено все пространство данных, пока $C^* = p$, где p — исходная размерность. Наша задача — сосредоточиться на подмножестве компонент, чтобы $C^* < p$, чтобы упростить данные. Уникальность компонент определяется требованием, чтобы каждая компонента была ортогональна всем остальным. То есть, каждая новая компонента объясняет уникальную вариацию в данных.

Формализация PCA. Так как PCA – частный случай линейной регрессии, то уравнение строится аналогичным образом, но без оценивания параметров и свободного члена. Каждый признак вносит свой вклад в вычисление главных компонент, веса называются нагрузками (loadings). Для поиска оптимальных значений предлагается использование SVD (сингулярное разложение матрицы). Последним шагом является выбор кол-ва ГК через PVE (долю объясненной дисперсии). PVE в диапазоне от 75–80 процентов. CPVE – накопленная доля объясненной дисперсии, равная 1. Главная проблема PCA – неопределенность относительно метода выбора ГК.

Локально линейные вложения. Глава 3.

LLE позволяет описывать более сложную структуру данных и нелинейные пространства данных. Отличие от PCA – LLE изучают локальные структуры, далее проецируя на глобальную. Цель LLE – изучить форму (*shape*), эта форма называется многообразием (*manifold*).

Многообразие и сложная структура. Многообразие – геометрическая форма размерности d , которая локально рассматривается как евклидово пространство. Предполагается, что в нелинейном пространстве при рассмотрении локально – все наблюдения вдоль него являются линейными.

Риманово многообразие – входное пространство данных можно охарактеризовать через некоторое латентное, более простое многообразие, но расположенное в пространстве высокой размерности (окружающее пространство).

Так, задача сокращения размерности:

1. Изучить форму и контуры скрытого многообразия.
2. Воспроизвести реальную структуру в пространство меньшей размерности.

Ключевое – баланс между локальной и глобальной структурой. Локальная структура – описание пространства в окрестности каждой отдельной точки, объединяя локальные приближения – мы получаем глобальную структуру.

Формализация LLE. LLE реконструирует пространство данных на основе точечных локальных вычислений схожести, вычисляется приближение для каждого наблюдения на основе взвешенной линейной комбинации ближайших соседей данной точки. Далее взвешенные локальные представления точек комбинируются для представления глобальной структуры данных. То есть, мы ищем веса линейных комбинаций в локальном масштабе, перемножаем веса с исходными признаками, а затем складываем, чтобы получить приближенное представление данной точки.

Нам интересна линейная комбинация взвешенных признаков с целью построения приближения для каждой точки. Эти веса находятся в центре метода и обозначаются через β . Веса рассчитываются на основе расстояний между наблюдением и его окружением:

$$\sum_{j=1}^k \beta_{ij} = 1$$

Чем выше значение веса, тем ближе точка j к i , и тем больше она похожа на точку i .

Наша задача – минимизировать ошибку (например, MSE). Используя набор весов, полученных нами путем минимизации RSS – мы находим набор двумерных координат, что обеспечивает минимальную глобальную ошибку.

Нелинейное снижение размерности для визуализации. Глава 4.

Уменьшение размерности как инструмент визуализации через t-SNE и UMAP. Данные методы позволяют рассматривать нелинейные комбинации исходных данных. Оба метода опираются на сглаживание на основе соседей для построения локальных представлений. В отличие от LLE, исходные признаки не взвешиваются и рассчитываются только расстояния в пределах локальных окрестностей.

На основе локальных расстояний выполняется попытка воссоздания многообразия. Близкие расстояния между объектами в исходных данных, становятся близкими и в пространстве меньшей размерности, аналогично и с отдаленными друг от друга объектами.

t-SNE. В основе алгоритма лежит сравнение вероятностных распределений. Первоначальная структура данных сравнивается с новым представлением в пространстве меньшей размерности с использованием метрики для сравнения распределений – Kullback–Leibler (KL) divergence. Низкие значения KL-

дивергенции означают, что распределения очень похожи, а высокие – что они значительно отличаются друг от друга. Первым шагом является рассмотрение расстояний между наблюдениями i и ее соседями j . Далее расстояния нормализуются и превращаются в вероятности, чем выше вероятность, тем ближе i к j .

Следующий шаг: создание новой случайно распределенной версии данных в меньшей размерности, чаще всего в двух измерениях ($d=2$). Далее опять проводится процесс построения распределения вокруг каждого наблюдения и вычисляется вероятного того, что наблюдения находятся близко друг к другу. Но на этот раз используется распределение Стюдента, чтобы уменьшить неопределенность. После формирования новых наборов вероятностей, алгоритм отдаляет наблюдения с малой вероятностью и приближает с большой. Далее происходит сравнение распределений с помощью сравнения с исходной матрицей, мерой разницы служит функция стоимости. Мера функции стоимости, которая отражает различия между этими версиями, – это метрика KL-divergence, иногда называемая относительной кросс-энтропией.

$$\sum_{x \in \mathcal{X}} x_h \log \left(\frac{x_h}{x_l} \right)$$

Каждое распределение вероятностей x_* в полном вероятностном пространстве данных X сравнивается на основе логарифмической относительной разницы между версией высокой размерности x_h и версией низкой размерности x_l . Если вероятности в пространстве меньшей размерности становятся больше похожи на вероятности исходного пространства, то значение метрики уменьшается, что указывает на снижение различий в пространстве данных. Алгоритм останавливается, когда метрика минимальна.

Гиперпараметры: perplexity (показатель запутанности). Чем выше перплексия, тем более "глобальное" решение, низкие значения перплексии говорят о фокусировании, алгоритм более сосредоточен на локальных связях между точками. Перплексия создает более узкие распределения вокруг каждой точки, что удалённые точки будут рассматриваться как похожие на рассматриваемое наблюдение i в центре распределения. Меньше значения перплексии лучше восстанавливают локальную структуру данных. Два подхода выбора гиперпараметра: вручную измерять значения, grid search.

UMAP. UMAP опирается на гладкие геометрические расстояния. UMAP сначала анализирует структуру многообразия, а потом локально проецирует ее. В рамках UMAP проводится: поиск между точками для установления связей между ними, если точки находятся в пределах этой области, то они соединяются. Затем, поиск вокруг областей точек для уточнения локальной структуры, строится нервная сеть многообразия.

Функция стоимости UMAP:

$$\sum_{x \in \mathcal{X}} x_h \log \left(\frac{x_h}{x_l} \right) (1 - x_h) \log \left(\frac{1 - x_h}{1 - x_l} \right)$$

Вычисление точечных показателей:

$$x_{j|i} = \exp \left[-\frac{d(i, j) - \rho_i}{\sigma_i} \right]$$

Гиперпараметры (ρ и σ) – управляют процессом сглаживания. А также: метрика k (соседи), эпохи (кол-во раз, когда алгоритм видит данные), метрики.