

Сокращение размерности. Глава 1.

1. **Размерности** — переменные или характеристики данных (столбцы в матрице X). $X (N \times P)$: N — число наблюдений (строк), P — число признаков (столбцов). Чем больше признаков, тем сложнее данные. Алгоритм лучше всего работает именно с непрерывными данными.
2. **Сокращение размерности**: мы берём данные с высокой размерностью ($p > 4$) и «упрощаем» их (до $p = 2$). То есть, мы представляем полное пространство данных высокой размерности в подпространстве меньшей размерности.

Например, МГК (РСА) — метод, уменьшающий размерность и максимизирующий общую дисперсию. Первая ГК определяется через направление наибольшей вариации данных, последующие компоненты ортогональны предыдущим, что отражает уникальные данные. Определение числа компонент зависит от исследователя, но количество компонент должно быть $< p$, так как из любого пространства X можно извлечь до p компонент.

УМАР — изучение геометрического пространства и геометрических паттернов, которые лежат в пространстве высокой размерности, и, основываясь на расстояниях между наблюдениями, уменьшает размерность исходных данных. Свои основания UMAP (Uniform Manifold Approximation and Projection) берёт в методе t-SNE (t-distributed Stochastic Neighbor Embedding).

Про массив данных: термометр чувств от 1 до 100 по поводу того, какие чувства респонденты испытывают к тому или иному человеку/феномену. Ценность в том, что они, скорее всего, коллинеарны. **Гипотеза**: структура ответов на эти термометры будет формироваться по партийной линии.

LLE имеет схожую с РСА интуицию: основан на идее «многообразного» обучения через изучение локальной структуры (из соседних значений) и дальнейшей её интерпретации на глобальную структуру. Метод подходит, если данные не выражаются линейно. Он сохраняет локальные связи между точками, что позволяет работать с более сложными структурами данных. Схожим образом работают t-SNE и UMAP, а также нейронные модели: SOM и autoencoders.

Чем РСА отличается от факторного анализа? Факторный анализ предполагает ряд предварительных допущений о гауссовском распределении и существовании условной независимости между переменными. Фокус на латентных переменных, каузальная модель, которая пытается выявить скрытые факторы.

Очистка данных. Два подхода для очистки данных в R: базовый синтаксис и tidy-подход. Tidy-подход — использование операторов `%>%` для написания нескольких операций в одной функции. Вместо удаления используется импутация, то есть вычисленные правдоподобные значения. Также рекомендуется задуматься и о причинах пропусков значений. В случае случайных пропусков используется множественная импутация с помощью kNN: выбираются ближайшие непустые значения и берётся их среднее.

Классический подход к сокращению размерности. Глава 2.

РСА (МГК). Линейный подход к снижению размерности, который уменьшает сложность путем максимизации дисперсии (информативности). Изначально предполагается, что дисперсия — лучший способ концептуализации структуры в пространстве данных.

Почему РСА? МГК делает пространство высокой размерности менее сложным, позволяет бороться с мультиколлинеарностью. Также, снижение размерности помогает бороться с "проклятием размерности с точки зрения которого, настоящие сходства и различия между признаками становятся все менее очевидными.

Дисперсия задает критерий оптимальности, РСА начинается с поиска направления в данных, вдоль которого наблюдается БОЛЬШОЙ разброс. После нахождения направления проводится обобщаемая прямая — ГК, которая и отражает направление максимальной дисперсии (ГК1). ГК1 объясняет не все данные, поэтому мы ищем ГК пока не будет объяснено все пространство данных, пока $C^* = p$, где p — исходная размерность. Наша задача — сосредоточиться на подмножестве компонент, чтобы $C^* < p$, чтобы упростить данные. Уникальность компонент определяется требованием, чтобы каждая компонента была ортогональна всем остальным. То есть, каждая новая компонента объясняет уникальную вариацию в данных.

Формализация PCA. Так как PCA – частный случай линейной регрессии, то уравнение строится аналогичным образом, но без оценивания параметров и свободного члена. Каждый признак вносит свой вклад в вычисление главных компонент, веса называются нагрузками (loadings). Для поиска оптимальных значений предлагается использование SVD (сингулярное разложение матрицы). Последним шагом является выбор кол-ва ГК через PVE (долю объясненной дисперсии). PVE в диапазоне от 75–80 процентов. CPVE – накопленная доля объясненной дисперсии, равная 1. Главная проблема PCA – неопределенность относительно метода выбора ГК.

Локально линейные вложения. Глава 3.

LLE позволяет описывать более сложную структуру данных и нелинейные пространства данных. Отличие от PCA – LLE изучают локальные структуры, далее проецируя на глобальную. Цель LLE – изучить форму (*shape*), эта форма называется многообразием (*manifold*).

Многообразие и сложная структура. Многообразие – геометрическая форма размерности d , которая локально рассматривается как евклидово пространство. Предполагается, что в нелинейном пространстве при рассмотрении локально – все наблюдения вдоль него являются линейными.

Риманово многообразие – входное пространство данных можно охарактеризовать через некоторое латентное, более простое многообразие, но расположенное в пространстве высокой размерности (окружающее пространство).

Так, задача сокращения размерности:

1. Изучить форму и контуры скрытого многообразия.
2. Воспроизвести реальную структуру в пространство меньшей размерности.

Ключевое – баланс между локальной и глобальной структурой. Локальная структура – описание пространства в окрестности каждой отдельной точки, объединяя локальные приближения – мы получаем глобальную структуру.

Формализация LLE. LLE реконструирует пространство данных на основе точечных локальных вычислений схожести, вычисляется приближение для каждого наблюдения на основе взвешенной линейной комбинации ближайших соседей данной точки. Далее взвешенные локальные представления точек комбинируются для представления глобальной структуры данных. То есть, мы ищем веса линейных комбинаций в локальном масштабе, перемножаем веса с исходными признаками, а затем складываем, чтобы получить приближенное представление данной точки.

Нам интересна линейная комбинация взвешенных признаков с целью построения приближения для каждой точки. Эти веса находятся в центре метода и обозначаются через β . Веса рассчитываются на основе расстояний между наблюдением и его окружением:

$$\sum_{j=1}^k \beta_{ij} = 1$$

Чем выше значение веса, тем ближе точка j к i , и тем больше она похожа на точку i .

Наша задача – минимизировать ошибку (например, MSE). Используя набор весов, полученных нами путем минимизации RSS – мы находим набор двумерных координат, что обеспечивает минимальную глобальную ошибку.

Нелинейное снижение размерности для визуализации. Глава 4.

Уменьшение размерности как инструмент визуализации через t-SNE и UMAP. Данные методы позволяют рассматривать нелинейные комбинации исходных данных. Оба метода опираются на сглаживание на основе соседей для построения локальных представлений. В отличие от LLE, исходные признаки не взвешиваются и рассчитываются только расстояния в пределах локальных окрестностей.

На основе локальных расстояний выполняется попытка воссоздания многообразия. Близкие расстояния между объектами в исходных данных, становятся близкими и в пространстве меньшей размерности, аналогично и с отдаленными друг от друга объектами.

t-SNE. В основе алгоритма лежит сравнение вероятностных распределений. Первоначальная структура данных сравнивается с новым представлением в пространстве меньшей размерности с использование метрики для сравнения распределений – Kullback–Leibler (KL) divergence. Низкие значения KL-

дивергенции означают, что распределения очень похожи, а высокие – что они значительно отличаются друг от друга. Первым шагом является рассмотрение расстояний между наблюдениями i и ее соседями j . Далее расстояния нормализуются и превращаются в вероятности, чем выше вероятность, тем ближе i к j .

Следующий шаг: создание новой случайно распределенной версии данных в меньшей размерности, чаще всего в двух измерениях ($d=2$). Далее опять проводится процесс построения распределения вокруг каждого наблюдения и вычисляется вероятного того, что наблюдения находятся близко друг к другу. Но на этот раз используется распределение Стюдента, чтобы уменьшить неопределенность. После формирования новых наборов вероятностей, алгоритм отдаляет наблюдения с малой вероятностью и приближает с большой. Далее происходит сравнение распределений с помощью сравнения с исходной матрицей, мерой разницы служит функция стоимости. Мера функции стоимости, которая отражает различия между этими версиями, – это метрика KL-divergence, иногда называемая относительной кросс-энтропией.

$$\sum_{x \in \mathcal{X}} x_h \log \left(\frac{x_h}{x_l} \right)$$

Каждое распределение вероятностей x_* в полном вероятностном пространстве данных X сравнивается на основе логарифмической относительной разницы между версией высокой размерности x_h и версией низкой размерности x_l . Если вероятности в пространстве меньшей размерности становятся больше похожи на вероятности исходного пространства, то значение метрики уменьшается, что указывает на снижение различий в пространстве данных. Алгоритм останавливается, когда метрика минимальна.

Гиперпараметры: perplexity (показатель запутанности). Чем выше перплексия, тем более "глобальное" решение, низкие значения перплексии говорят о фокусировании, алгоритм более сосредоточен на локальных связях между точками. Перплексия создает более узкие распределения вокруг каждой точки, что удаленные точки будут рассматриваться как похожие на рассматриваемое наблюдение i в центре распределения. Меньше значения перплексии лучше восстанавливают локальную структуру данных. Два подхода выбора гиперпараметра: вручную измерять значения, grid search.

УМАР. UMAP опирается на гладкие геометрические расстояния. UMAP сначала анализирует структуру многообразия, а потом локально проецирует ее. В рамках UMAP проводится: поиск между точками для установления связей между ними, если точки находятся в пределах этой области, то они соединяются. Затем, поиск вокруг областей точек для уточнения локальной структуры, строится нервная сеть многообразия.

Функция стоимости UMAP:

$$\sum_{x \in \mathcal{X}} x_h \log \left(\frac{x_h}{x_l} \right) (1 - x_h) \log \left(\frac{1 - x_h}{1 - x_l} \right)$$

Вычисление точечных показателей:

$$x_{j|i} = \exp \left[-\frac{d(i, j) - \rho_i}{\sigma_i} \right]$$

Гиперпараметры (ρ и σ) – управляют процессом сглаживания. А также: метрика k (соседи), эпохи (кол-во раз, когда алгоритм видит данные), метрики.

Подходы, основанные на нейронных сетях. Глава 5.

Нейронная сеть состоит из трех слоев: входного, скрытого и выходного. Входной слой – стандартная матрица X из исходных входных признаков. Выходной слой – зависимая переменная/признак, здесь формируются предсказания выходных данных. В скрытом слое происходит обработка данных, он находится между входом и выходом.

Нейронная сеть соединена весами и смещениями (bias). Вес – значение, присвоенное ребрам сети, соединяющим узлы и составляющим каждый слой, а смещение другой тип весов, назначаемых каждому узлу. Все смещения присваиваются случайным образом.

Задача нейронной сети – пропустить необработанные данные через сеть по одному или нескольким наблюдениям за раз (батчи). Сначала сеть обрабатывает данные в скрытом слое, затем выдается решение. Предсказание сравнивается с уже размеченными значениями и ошибка фиксируется. Далее данные передаются обратно через сеть через обратное распространение ошибки (backpropagation).

Через обратное распространение веса и смещения итеративно обновляются шагами в ответ на ошибку, зафиксированную после прямого прохода данных (forward propagation). Далее через сеть пропускаются новые батчи, но с использованием новых весов и смещений, которые были выучены на предыдущей итерации. Ошибка снова фиксируется после прямого распространения, а затем после обратного распространения веса и смещения обновляются еще раз.

Полный просмотр всех данных – эпоха. Мы продолжаем обучение пока не достигнем некоторого порога, например, задавая гиперпараметром количество эпох. Также важным гиперпараметром является размер шага (lr).

Нейронные сети: полносвязная искусственная прямая нейронная сеть (ее принципы уже описаны) или сверточная нейронная сеть (используется для распознавания изображений).

SOM. Первоначально метод был основан на топологическом анализе данных и связан с кластеризацией. В SOM отсутствует скрытый слой для обработки данных. Входной слой напрямую соединяется с выходным. Мы заранее определяем количество узлов, которые далее соревнуются между собой за право представлять определённую часть данных в двумерном выходном слое. Близкие по признакам наблюдения группируются вместе. SOM можно рассматривать как сочетание нейронных сетей, кластеризации и уменьшения размерности, объединённых в один метод. BMU (best matching unit) – побеждающий узел.

1. **Первый шаг – соревнование** — конкуренция узлов за представление входного пространства.
2. **Второй шаг – сотрудничество:** когда побеждающий узел становится центром соседства узлов в выходном слое.
3. **Третий шаг – обучение:** узлы в области соседства BMU участвуют в обновлении весов вместе.

- На шаге соревнования для каждого выходного нейрона j мы вычисляем расстояние между вектором весов и входным вектором $d(W, X)$.

- BMU i выбирается как узел, минимизирующий это расстояние.

- На шаге сотрудничества определяются все узлы в выходном слое j , находящиеся в области соседства узла i (размер области задаётся R или σ).

- На шаге обучения для всех узлов в этой области мы обновляем веса по формуле.

Остановка по критерию останова.

Автоэнкодеры. Воспроизводит логику PCA, но только в нейросетевом ключе.

1. **Первый шаг – кодирование:** сжатие данных.
2. **Второй шаг – реконструкция.**

Мы можем вычислить ошибку (сравнивая декодированную версию с исходной), которая называется ошибка реконструкции (reconstruction error), при этом мы остаёмся в рамках обучения без учителя. Автоэнкодер учится на данных в режиме без учителя. Как и в PCA, из автоэнкодера мы получаем набор вновь построенных признаков. В автоэнкодерах – кодировки (codings) или глубокие признаки (deep features), в зависимости от глубины сети.

Числа узлов или нейронов в скрытом слое. Если их больше, чем во входном слое, то такой автоэнкодер будет считаться overcomplete (с избыточным кодированием). Это противопоставляется undercomplete автоэнкодеру, где число узлов в скрытом слое меньше, чем во входном слое.